

# **Pronósticos simples: fundamentos teóricos y conceptos clave**

Fundamentos teóricos y criterios de selección

— SESIÓN TEÓRICA

# Objetivos y agenda



## Objetivos de aprendizaje

- ✓ Comprender los fundamentos teóricos y supuestos de los modelos de pronóstico simples.
- ✓ Identificar los componentes de una serie temporal y su relación con la elección del método.
- ✓ Evaluar el desempeño de los modelos utilizando métricas de error y criterios de validación.

## Agenda de la clase

1. Introducción y Conceptos	10 min
2. Diagnóstico y Componentes	15 min
3. Métodos y Fórmulas Teóricas	15 min
4. Validación y Métricas	10 min
5. Selección y Resumen	10 min

ⓘ Enfoque 100% teórico y conceptual.

# ¿Qué es un pronóstico?

Definición, propósito y realidades estadísticas

## Definición Conceptual



*"Es el proceso de estimar eventos futuros basándose en datos históricos y el análisis de patrones, con el fin de reducir la incertidumbre en el presente."*

## Propósito Fundamental

- › **Toma de decisiones:** Provee una base racional para la planeación y asignación de recursos.
- › **Reducción de Riesgos:** Identifica posibles escenarios futuros para mitigar impactos negativos.

## ⚠ Limitaciones e Incertidumbre

- › **Inexactitud:** Ningún modelo es perfecto; siempre existe un error residual (ruido).
- › **Horizonte de tiempo:** La precisión disminuye significativamente a medida que el pronóstico se aleja del presente.



# Componentes de una serie temporal

*Descomposición conceptual de los datos históricos*



## Nivel

El valor base o promedio de la serie si se eliminaran los demás componentes.



## Tendencia

Dirección a largo plazo de los datos (creciente, decreciente o estable).



## Estacionalidad

Patrones que se repiten en intervalos fijos de tiempo (días, meses, trimestres).



## Ciclo

Fluctuaciones de larga duración sin un periodo constante (fases económicas).



## Ruido (Residual)

Variaciones aleatorias e impredecibles que no pueden ser explicadas por el modelo.

*"La mayoría de los métodos de pronóstico intentan aislar y predecir los componentes sistemáticos, descartando el ruido."*

# Diagnóstico previo al modelado

Antes de elegir un modelo, debemos entender la naturaleza de los datos.

## 1. Visualización

Inspección visual de la serie cruda para identificar:

- Valores atípicos (outliers)
- Saltos estructurales o cambios de régimen
- Variabilidad no constante

## 2. Descomposición

Separar la serie en sus componentes fundamentales:

- Tendencia (movimiento a largo plazo)
- Estacionalidad (patrones repetitivos)
- Residuo (ruido aleatorio)

## 3. ACF / PACF

Análisis de la función de autocorrelación para buscar:

- Persistencia de la memoria
- Periodicidad oculta
- Decaimiento (indicio de estacionariedad)

## 4. Pruebas de Estacionariedad

Validación formal de propiedades estadísticas:

- Prueba de Dickey-Fuller Aumentada (ADF)
- Verificar media y varianza constantes
- Necesidad de diferenciación

# Métodos simples - panorama conceptual

Estrategias fundamentales para la proyección de series temporales

## ⌚ Método Naïve

**Idea:** El último valor observado es el mejor pronóstico para el futuro.

**Supuesto:** *No hay patrón de tendencia ni estacionalidad; solo ruido aleatorio.*

## 〽️ Media Móvil (SMA/WMA)

**Idea:** Promedia los últimos \$k\$ periodos para "suavizar" el ruido.

**Supuesto:** *El nivel de la serie es relativamente estable en el tiempo.*

## 〽️ SES

**Idea:** Promedio ponderado donde el peso decae de forma exponencial hacia el pasado.

**Supuesto:** *Útil para datos sin tendencia, pero que cambian de nivel lentamente.*

## ↗️ Método de Holt

**Idea:** Extensión de SES que incluye una ecuación para capturar la tendencia.

**Supuesto:** *La serie presenta una tendencia lineal (creciente o decreciente) sostenida.*



# Fórmulas clave

MODELADO MATEMÁTICO

## SMA Media Móvil Simple

$$\hat{y}_{t+1} = (1/k) \sum y_{t-i}$$

**k:** Ventana de tiempo (suavizado). A mayor k, mayor estabilidad y menor respuesta a cambios.

## WMA Media Móvil Ponderada

$$\hat{y}_{t+1} = \sum (w_i * y_{t-i})$$

**w<sub>i</sub>:** Pesos asignados ( $\sum w=1$ ). Suele dar más peso a datos recientes.

## SES Suavizamiento Exponencial

$$\ell_t = \alpha y_t + (1 - \alpha) \ell_{t-1}$$

**α:** Constante de suavizado [0,1]. Controla la velocidad de ajuste al último dato.

## HOLT Suavizamiento Lineal (Tendencia)

$$\begin{aligned}\ell_t &= \alpha y_t + (1-\alpha)(\ell_{t-1} + b_{t-1}) \\ b_t &= \beta * (\ell_t - \ell_{t-1}) + (1-\beta) * b_{t-1}\end{aligned}$$

**β\*:** Parámetro de tendencia. Permite al modelo capturar direcciones de crecimiento/caída.

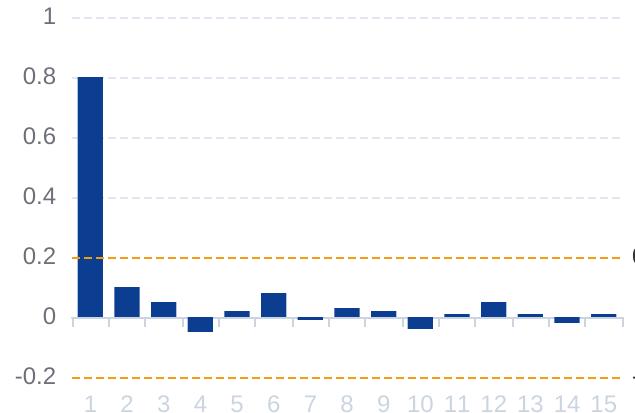
\* Nota:  $\hat{y}_{t+h}$  para Holt se calcula como  $\ell_t + h*b_t$



# Interpretación de la ACF y elección de método

La Función de Autocorrelación como brújula diagnóstica para el modelado.

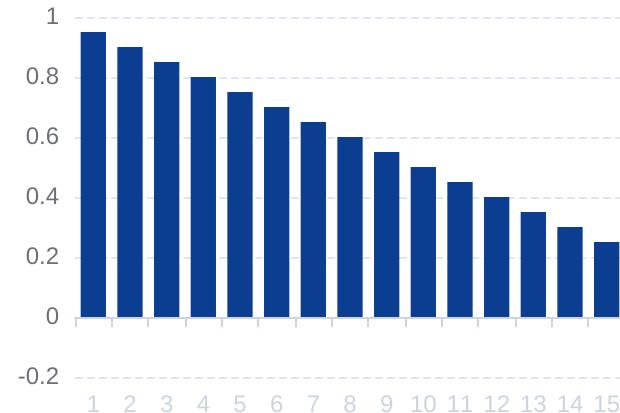
## ↗ Estacionariedad



Patrón: Caída rápida a cero.

MÉTODO SUGERIDO:  
SES o Media Móvil

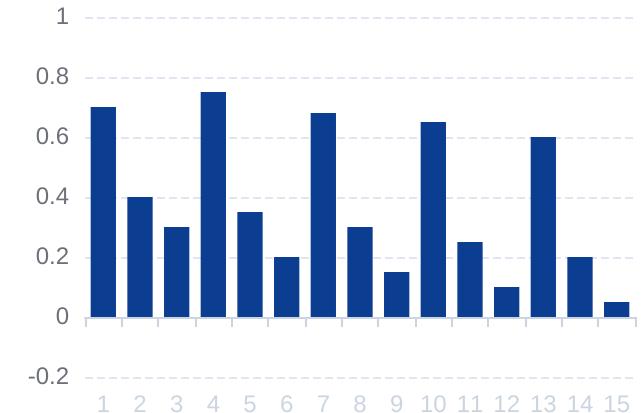
## ↖ Tendencia



Patrón: Descenso lento y lineal.

MÉTODO SUGERIDO:  
Método de Holt

## ⟳ Estacionalidad



Patrón: Picos en rezagos estacionales.

MÉTODO SUGERIDO:  
Naive Estacional

💡 Regla de oro: Si la ACF no muestra correlaciones significativas (ruído blanco), no hay patrones que predecir.

ACF Analysis Phase

# Validación y métricas de desempeño

¿Cómo medimos el éxito?

## MAE

Error Absoluto Medio

- ✓ Promedio de errores en valor absoluto.
- ✓ Fácil de interpretar (mismas unidades que la serie).
- ✓ Trata todos los errores por igual.

## RMSE

Raíz del Error Cuadrático Medio

- ✓ Penaliza más los **errores grandes** (outliers).
- ✓ Útil cuando los errores grandes son costosos.
- ✓ Sensible a valores atípicos.

## MAPE

Error Porcentual Absoluto Medio

- ✓ Mide el error en términos relativos (%).
- ✓ Permite comparar series con **diferentes escalas**.
- ✓ Problemas si hay valores cercanos a cero.

## ⚠ Consideraciones críticas para la elección

⚖ **Escala de los datos:** Use MAPE si necesita comparar el desempeño entre productos con volúmenes de venta muy distintos.

↖ **Impacto de Outliers:** Si un error grande puede quebrar la operación, optimice para **RMSE** para ser conservador.

## Bandas de Predicción

Representan el rango donde se espera que el valor real se ubique con una probabilidad determinada.

**80%**

Intervalo "Central"

**95%**

Intervalo "Conservador"

- ⚠ A mayor horizonte de tiempo, la incertidumbre (y el ancho de la banda) aumenta.
- ✓ Se basan en la desviación estándar de los residuos del modelo.

## Mensajes para audiencias no técnicas

### 1 Evitar el "Número Único"

Presentar el pronóstico como un escenario probable, no como una promesa exacta.

### 2 Usar Escenarios

Hablar de "caso base", "optimista" (límite superior) y "pesimista" (límite inferior).

### 3 Enfoque en Decisiones

¿Qué acción debemos tomar si el valor cae en el extremo de la banda?



"La precisión es un objetivo; la incertidumbre es una realidad."

# Guía práctica para elegir método

FLUJO DE TRABAJO Y CRITERIOS DE DECISIÓN RÁPIDA

## ☰ Checklist Sistemático

### 1 Diagnóstico

Visualización, descomposición y análisis de ACF.

### 2 Selección de Familia

Identificar patrones (tendencia/estacionalidad).

### 3 Validación

Cálculo de RMSE, MAE y MAPE en set de prueba.

### 4 Comunicación

Añadir intervalos de confianza y contexto.

## ⚡ Criterios de Selección Rápida

### ¿Sin Tendencia ni Estacionalidad?

Usar **Naive**, **Media Móvil** o **SES**. Ideal para datos estables o "ruido blanco".

### ¿Presencia de Tendencia?

Usar **Método de Holt**. Permite capturar el crecimiento o decrecimiento sostenido.

### ¿Mucho Ruido / Pocos Datos?

Priorizar **Media Móvil (SMA)** para suavizar y detectar el nivel subyacente.

# RESUMEN Y PRÓXIMOS PASOS

Cierre teórico y hoja de ruta de aprendizaje

## 💡 Conclusiones Teóricas

- ✓ El **diagnóstico previo** (ACF/PACF) es innegociable para entender la estructura de la serie.
- ✓ Los **métodos de suavizado** (SES y Holt) son la base para proyecciones de corto plazo con nivel y tendencia.
- ✓ La **validación** debe ser integral, usando métricas de error (MAE/RMSE) e intervalos de confianza.

## ↗ Hacia Modelos Avanzados

### Holt-Winters

Incorporación de componentes estacionales aditivos y multiplicativos.

### ARIMA / SARIMA

Modelado de la autocorrelación y diferenciación para series no estacionarias.

### Modelos Causales

Integración de variables externas y factores explicativos en el pronóstico.

# Referencias bibliográficas

Lecturas recomendadas y recursos adicionales



## Hyndman, R. J., & Athanasopoulos, G. (2021)

*Forecasting: Principles and Practice* (3rd ed.). OTexts: Melbourne, Australia.

RECURSO ABIERTO / REFERENCIA PRINCIPAL



## Montgomery, D. C., Jennings, C. L., & Kulahci, M. (2015)

*Introduction to Time Series Analysis and Forecasting*. John Wiley & Sons.

ENFOQUE ESTADÍSTICO RIGUROSO



## Makridakis, S., Wheelwright, S. C., & Hyndman, R. J. (1998)

*Forecasting Methods and Applications*. John Wiley & Sons.

CLÁSICO DE LA DISCIPLINA



OTexts.com

Libro de texto gratuito y ejemplos en R.



International Institute of Forecasters

Últimos avances y estándares globales.